Práctica de Laboratorio: Clasificación de Correo SPAM usando Perceptrón Multicapa

Objetivo

Implementar y entrenar un perceptrón multicapa (MLP) que clasifique correos electrónicos como SPAM o NO-SPAM a partir de características básicas extraídas del texto.

Parte 1: Contexto del Problema

El filtrado de correos electrónicos SPAM es un problema clásico en clasificación binaria. A partir de un conjunto de correos electrónicos etiquetados, se entrenará un perceptrón multicapa para aprender a distinguir patrones que permiten decidir si un mensaje es SPAM (1) o NO-SPAM (0).

Parte 2: Conjunto de Datos Sugerido

Utilizar una versión simplificada del dataset UCI Spambase, que se encuentra en la carpeta de laboratorios como archivo spambase.zip. Ahí están los datos y su descripción. Las variables de entrada pueden incluir:

- Frecuencia de palabras como 'free', 'win', 'money'
- Presencia de caracteres como '!'
- Longitud del mensaje en mayúsculas
- Salida: 1 si es SPAM, 0 si NO.

Parte 3: Arquitectura de la Red

Decide la arquitectura de la red, deberá hacer experimentos para determinarla. Decide:

- No. de entrada
- Capas ocultas
- La salida será: 1 neurona (clasificación binaria)
- Activación: tanh o sigmoid
- Pérdida: Error cuadrático medio
- Algoritmo de entrenamiento: Retropropagación con descenso de gradiente

Parte 4: Actividades del Estudiante

1. Implementar el MLP en Python usando NumPy.
2. Entrenar con el dataset establecido.
3. Experimentar con diferentes tasas de aprendizaje, por ejemplo: 0.001 0.01, 0.05 y número de épocas, por ejemplo: 500, 1000, 2000.
4. Evaluar el rendimiento con:

Precisión, recuerdo, medida F
Matriz de confusión
Error de entrenamiento por épocas

Parte 5: Análisis Requerido

1. ¿Qué configuración de tasa de aprendizaje y épocas produjo mejores resultados?
2. ¿Qué métricas usaste para medir el rendimiento?
3. ¿Qué cambios harías para mejorar la red?
4. ¿Cómo interpretas los errores de clasificación?

Criterios de Evaluación

Criterio	Puntos
Código funcional y documentado	30
Análisis de experimentos	20
Gráficos generados	20
Respuestas de análisis	20
Presentación de resultados	10